報酬に基づくブロック運搬動作の選択

CEM による指の閉じ角と持ち上げ量の探索

Physical AI 応用 1 最終課題

ブロックをゴールへ運ぶ際、到達したかどうかだけでなく、どのように運んだかも評価したいと考えた。そこで、ゴールへの報酬に机上の滑り距離への減点を加え、指の閉じ角と手首の上昇量を探索した。把持の教師データは使わず、シミュレーションで得た報酬から設定を選んだ。

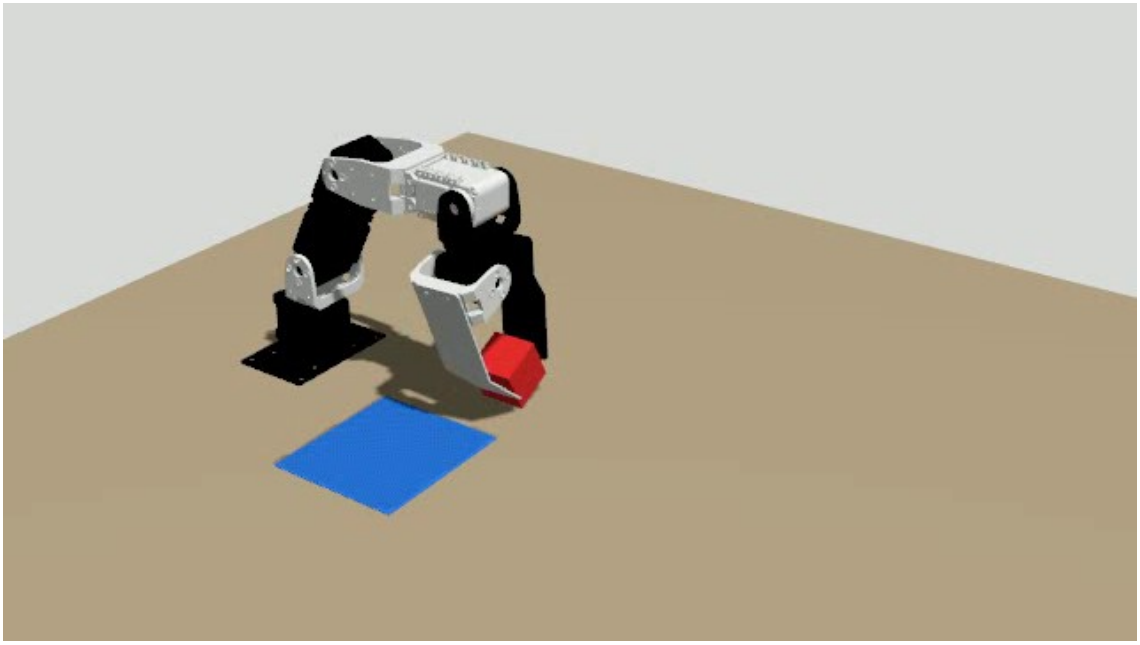


図 1　探索で選ばれた方策が赤いブロックを運ぶ様子

目的と結果の概要

初回の比較では、ゴール到達は探索前後とも 3 回中 3 回だった。一方、机上の滑り距離の平均は 89.7mm から 32.9mm へ約 63%減り、最大上昇量の平均は 0.46mm から 12.68mm へ変化した。持ち上げ自体への加点は与えていない。

接近、移動、開放の順序はあらかじめ与え、その中で二つの連続値を調整した。したがって、動作の順序全体を学習した実験ではない。ニューラルネットの追加学習ではなく、CEM（Cross Entropy Method）による直接方策探索を用いた。

システム構成と方策の設計

Docker 内で ROS 2 が関節指令と状態を橋渡しし、Gazebo が机とブロック、指の衝突を計算する。ブロックの移動は物理接触のみで発生し、試行中に物体を固定したり位置を書き換えたりしない。

項目	設定
ロボットと環境	CRANE+ V2　ROS 2 Humble　Ignition Gazebo 6.16.0
探索プログラム	Python 3.10.12　NumPy 1.24.4　CPU 実行
ブロック	一辺 30mm　質量 8g　SDF 摩擦係数 2.0
開始位置とゴール中心	開始 x=0.130 y=0.020m　ゴール x=0.112 y=−0.070m
関節出力の順序	joint1 joint2 joint4 joint3 gripper の 5 軸
制御周期と時間	約 20Hz の関節目標角指令　各試行 25 秒の実時間
観測と撮影	関節状態　物体 pose　実接触センサー　カメラ topic

動作の骨格は、home 姿勢、接近、下降、指の角度変更、手首目標の上昇、ゴール方向への回転、下降、開指、退避の順とした。逆運動学と smoothstep 補間で各区間をつなぎ、同じ処理に異なる 2 つのパラメータを与える。

自動探索する変数	範囲	初期値	選ばれた値
指の閉じ角 g	−0.52 ~ +0.60rad	−0.52rad	0.523454rad
手首目標の上昇量 h	0 ~ 50mm	0mm	17.692mm

h は IK で指定する手首目標高さの差であり、ブロックの実測上昇量ではない。IK に与える接触高さはロボット基準で 0.14m とし、移動方向の回転角−0.70rad、区間の時間と到達範囲を保つ傾きも固定した。机上面は world 座標 z=1.015m、静止時のブロック中心は z=1.030m である。ゼロ上昇かつ開指の初期設定では、机上を押して移動する。

探索で変えるのは表に示した二つの値だけである。「押す」「掴む」を選ぶ条件分岐や、成功する把持設定の手動挿入はない。ニューラルネット、事前学習重み、LoRA、教師データは使用していない。各区間で計算した目標角へ、ROS 側の関節制御器を使って追従させた。

報酬と探索アルゴリズム

e を終了時のゴール中心との XY 誤差、s を机との接触中に移動した XY 距離、z をブロック中心の終端高さとする。距離は m、角度は rad で計算し、主探索の前に次の重みを固定した。

$$R = Rgoal - 300\,s - C(g,h) - 100\,|z - 1.03|$$

$$Rgoal = 20\ \exp\left[-0.5\left(\frac{e}{0.03}\right)^2\right] + 8\ Igoal$$

$$C(g,h) = 0.5\ \left[\left(\frac{g + 0.52}{1.12}\right)^2 + \left(\frac{h}{0.055}\right)^2\right]$$

Igoal は e≤0.03 かつ |z−1.03|<0.015 のとき 1、それ以外は 0 とする。これは位置と高さの判定であり、速度による完全静止の判定ではない。全候補は終了前に開指し、制御終了から 1 秒後に終端位置を測る。

ゴールに近づくほど報酬を増やし、到達条件を満たした場合は加点する。一方、机に接触したまま長く移動すると減点する。C は閉指量と上昇量を抑える小さなコストであり、消費工ネルギーの実測値ではない。把持や持ち上げの成否に直接の加点は設けていない。0.055 は正規化用の定数で、探索上限の 0.050m とは異なる。

s は Gazebo の接触センサーが出す衝突名から測る。連続する 2 つの測定点のいずれかで机に接触していれば、その区間の XY 変位を滑りへ加算する。接触していない区間は別に記録する。約 20Hz のサンプリング近似であり、厳密な連続時間積分や摩擦仕事量ではない。

CEM は、複数の候補を評価し、報酬が高かった候補から次に試す分布を更新する方法である。本実装では 3 世代、各 12 候補を試し、上位 3 候補から平均と標準偏差を計算した。第 1 世代は Latin hypercube で範囲内に広く配置した。以降は一様探索 6 候補、正規分布 5 候補、それまでの最良候補の再試行 1 候補を組み合わせた。乱数 seed は 20261029、標準偏差の下限は探索範囲の 8%とした。

初期方策の 1 回と候補 36 回の計 37 回から、報酬だけで最良方策を選んだ。高さや把持ラベルでの選別はしない。予備確認で上昇量の上限を 55mm から 50mm へ修正したが、主探索中の報酬や範囲は変更していない。21 候補後の通信異常からは、保存履歴を使い同じ候補列の続きへ復帰した。

初回の比較評価と考察

探索で選んだ方策を固定し、初期方策と同じ開始配置で各 3 回実行した。初期方策は指を開き、手首を上昇させない設定である。これは、滑り減点なしで別に学習した方策との比較ではない。下表の 6 試行を提出動画に収録した。

方策と試行	報酬	滑り mm	最大上昇 mm	誤差 mm
前 1	0.87	89.6	0.50	4.9
前 2	0.84	89.7	0.52	4.9
前 3	0.79	90.0	0.37	4.5
後 1	16.92	31.8	14.35	9.9
後 2	17.06	33.3	11.22	6.5
後 3	15.89	33.7	12.48	11.9
前 平均	0.83	89.7	0.46	4.7
後 平均	16.62	32.9	12.68	9.5

前後とも 3 回すべてでゴールに到達した。探索後は、机に接触しない区間の XY 移動距離が平均 96.5mm となった。初期方策では 0mm だった。滑り距離は約 63％減ったが、完全にはなくなっていない。また、終端の XY 誤差は平均 4.7mm から 9.5mm へ増えた。位置精度を高めたというより、滑りの少ない運び方を選ぶ結果になった。

持ち上げに直接加点しなくても、浮かせて運ぶ設定が高い報酬を得た。ただし、今回試した 36 候補の中での最良値であり、最適性を保証するものではない。実測の上昇量は約 1cm で、手首に与えた約 1.8cm の上昇指令とは区別している。

滑り減点の影響を調べるため、同じ 37 試行を減点なしでも採点し直した。減点なしでは最大上昇 0.28mm、滑り 90.4mm の押し動作が最高点だった。減点ありでは最大上昇 14.2mm、滑り 30.6mm の候補が選ばれた。ただし、同じ実測結果の順位を比較しただけであり、二つの報酬で独立に学習した対照実験ではない。

動画は 1 分 2 秒で、前後各 3 試行をすべて収録し、下部の英語字幕に試行番号と実測値を示す。カメラはシミュレーション時間の 15fps で記録する。制御は実時間基準であるため、描画負荷によって 25 秒の制御と動画の秒数は一致しない。静止画像による時間延長や意図的な倍速化はしていない。

新しい環境での再現確認

2026 年 10 月 31 日、公開コードを別の作業場所へ取得し直し、固定した配布イメージから新しい Docker 環境を作成した。元のコンテナに追加したパッケージや ROS のビルド成果物は使っていない。保存済みの方策 JSON をコピーし、ハッシュの一致を確認してから再実行した。

確認した段階	今回の確認内容
環境とビルド	配布イメージの Python と NumPy を確認し、公開のセットアップ手順で ROS パッケージを新規ビルド
単体テスト	到達範囲、報酬、通信再試行など 6 項目が成功
保存記録の再計算	43 試行の候補列、報酬、接触距離、指令、方策ハッシュの検査が成功
物理的な再実行	保存された前後の方策を、新しいシミュレーションで各 3 回実行
実施していない確認	37 試行のオンライン探索全体の再学習、別 seed や別配置での一般化試験

次表は、到達回数を除き各 3 回の平均値を示す。

指標	初回 前	初回 後	再実行 前	再実行 後
ゴール到達	3/3	3/3	3/3	3/3
平均報酬	0.83	16.62	0.45	21.66
滑り mm	89.7	32.9	91.4	15.8
最大上昇 mm	0.46	12.68	0.01	22.76
終端誤差 mm	4.7	9.5	3.6	10.1

新しい環境でも、探索後の方策はブロックを浮かせて運び、初期方策より滑り距離が短くなった。保存した方策の実行と運び方の変化は再現できたが、数値は初回と一致していない。

seed を固定しても、物理接触や ROS の通信周期、CPU 負荷の影響は残る。この実装では実時間で動作区間を切り替えるため、負荷によって物理時刻の進み方が変わる。保存ログから候補列と報酬計算は検査できたが、探索全体をやり直して同じ最終値になるかは確認していない。

再実行の手順と今後の課題

コード一式と保存方策は、提出する GitHub リポジトリへ収録する。配布イメージの digest は以下のとおりである。新しい環境での実行ログ、6 試行の JSON、要約は、コード一式の reproduction_evidence に保存した。提出動画と初回評価の値は変更していない。

sha256:b58ec74c019aacd9ce4818fa25fc5a9e0a1f22f8c9cd1f5260994bf15cd9eb63

新規取得したコードのルートで Docker を起動し、コンテナ内の端末で環境確認と起動を行う。すでに Gazebo が動作している場合は同じコンテナで重ねて起動しない。

```
docker compose -f compose.block.yaml up -d
# コンテナ内の端末 1
bash /submission/tools/setup_reward_environment.sh
source /opt/ros/humble/setup.bash
source /home/ubuntu/airobot_ws/install/setup.bash
source /workspace/install/setup.bash
ros2 launch crane_act_demo block_reward.launch.py
```

別のコンテナ内端末でも上記 3 つの環境設定を読み込む。保存方策を新しい出力先へコピーし、以下の手順で前後各 3 回を実行する。これは探索をやり直さず、保存した方策を評価する手順である。

```
mkdir -p /workspace/repro_eval_run
cp /submission/experiments/submission3/policies/*.json \
  /workspace/repro_eval_run/
python3 /workspace/training/reward_search.py eval \
  --policy before --episodes 3 --root /workspace/repro_eval_run
python3 /workspace/training/reward_search.py eval \
  --policy after --episodes 3 --root /workspace/repro_eval_run
```

探索をやり直す場合は、別の出力先で search --generations 3 --population 12 を指定する。途中から再開する場合は --resume を追加する。audit_reward_run.py には、方策 JSON に加えて探索履歴と圧縮生ログを展開した一式が必要になる。詳細は experiments/submission3/README.md に記載した。

今回の対象は、既知の単一配置と軽いブロックに限られる。次に改善するなら、動作区間を物理時刻で管理し、滑り減点の有無で独立に探索した結果を比較したい。配置や seed を変えた評価も必要であり、現時点では未知配置での把持能力までは確認していない。

参考資料と権利関係

Mannor, S., Rubinstein, R. and Gat, Y. (2003). The Cross Entropy Method for Fast Policy Search. ICML 2003.
https://cdn.aaai.org/ICML/2003/ICML03-068.pdf
Duan, Y. et al. (2016). Benchmarking Deep Reinforcement Learning for Continuous Control. ICML 2016.
https://proceedings.mlr.press/v48/duan16.pdf

自作コード、生成データ、方策パラメータは Apache-2.0 とする。CRANE+は commit 19c1d6069126cd27488bf1bbefd410704bfc515d を使用し、配布元の Apache-2.0 に従う。ROS、Gazebo、Docker image などには各配布元の条件が適用される。詳細はコード一式の THIRD_PARTY_BLOCK.md を参照する。

提出コードには、保存方策、探索履歴、実行手順と検証記録を含める。